

UTS SUPERVISED LEARNING

Zilda Ainun Tazkia

2025-10-02

Latar Belakang

Tim data internal PT. Digital Cemerlang telah mencoba membangun sebuah model untuk memprediksi gaji karyawan (Gaji_Bulanan) berdasarkan 20 faktor lainnya. Namun, hasil model awal mereka sangat meragukan. Meskipun model tersebut memiliki kemampuan prediksi yang tampak tinggi, koefisien (pengaruh) dari beberapa variabel kunci tidak stabil dan seringkali bertentangan dengan logika bisnis. Terdapat kecurigaan kuat bahwa ada masalah mendasar dalam data atau metode yang digunakan.

Anda bertindak sebagai konsultan independen yang ditugaskan untuk melakukan audit menyeluruh. Tugas Anda adalah mengidentifikasi sumber masalah, membangun model alternatif yang lebih valid dan andal, serta memberikan rekomendasi akhir kepada manajemen.

Tujuan

Mendiagnosis kelemahan model linier standar pada dataset yang diberikan, menerapkan pendekatan pemodelan yang sesuai untuk memperbaiki masalah tersebut, dan memilih model final terbaik yang seimbang antara akurasi prediksi dan validitas inferensial.

```
library(readxl)
library(car)
```

```
## Loading required package: carData
```

```
library(glmnet)
```

```
## Loading required package: Matrix
```

```
## Loaded glmnet 4.1-10
```

```
library(knitr)
library(corrplot)
```

```
## corrplot 0.95 loaded
```

```
library(RColorBrewer)
library(ggplot2)
library(ggfortify)
library(lmtest)
```

```
## Loading required package: zoo
```

```
##
```

```
## Attaching package: 'zoo'
```

```
## The following objects are masked from 'package:base':
```

```
##
```

```
##      as.Date, as.Date.numeric
```

```
library(nlme)
```

```
library(caret)
```

```
## Loading required package: lattice
```

```
Gaji_bulanan <- read_excel("C:/Users/Lenovo IP Slim 3/Downloads/Raw Data Model Prediksi Gaji Bulanan.xlsx")
```

```
head(Gaji_bulanan)
```

```
## # A tibble: 6 x 21
```

```
##   Tingkat_Pendidikan Pengalaman_Kerja Pelatihan_Sertifikasi Jam_Kerja_Mingguan
```

```
##           <dbl>           <dbl>           <dbl>           <dbl>
```

```
## 1           9.41           4.03           5             51.1
```

```
## 2           17.0           1.28           4             40.2
```

```
## 3           12.0           8.38           1             48.8
```

```
## 4           10.7           7.85           3             51.0
```

```
## 5            8.51           8.27           2             34.6
```

```
## 6            8.51           3.41           7             36.8
```

```
## # i 17 more variables: Jumlah_Projek_Selesai <dbl>,
```

```
## #   Skor_Evaluasi_Kinerja <dbl>, Jumlah_Bawahan <dbl>,
```

```
## #   Lama_Di_Perusahaan <dbl>, Tingkat_Tanggung_Jawab <dbl>,
```

```
## #   Frekuensi_Lembur <dbl>, Jumlah_Klien_Ditangani <dbl>,
```

```
## #   Skor_Kepemimpinan <dbl>, Tingkat_Stress_Kerja <dbl>,
```

```
## #   Produktivitas_Harian <dbl>, Kemampuan_Komunikasi <dbl>,
```

```
## #   Inovasi_Dihasilkan <dbl>, Ketepatan_Deadline <dbl>, ...
```

```
summary(Gaji_bulanan)
```

```
## Tingkat_Pendidikan Pengalaman_Kerja Pelatihan_Sertifikasi Jam_Kerja_Mingguan
```

```
## Min. : 8.000 Min. : 1.067 Min. : 1.000 Min. :20.00
```

```
## 1st Qu.: 8.839 1st Qu.: 3.914 1st Qu.: 3.000 1st Qu.:36.71
```

```
## Median :10.079 Median : 5.962 Median : 4.000 Median :42.06
```

```
## Mean :10.969 Mean : 6.956 Mean : 4.027 Mean :42.12
```

```
## 3rd Qu.:12.136 3rd Qu.: 9.066 3rd Qu.: 5.000 3rd Qu.:47.54
```

```
## Max. :32.517 Max. :35.905 Max. :12.000 Max. :74.12
```

```
## Jumlah_Projek_Selesai Skor_Evaluasi_Kinerja Jumlah_Bawahan
```

```
## Min. : 2.206 Min. :47.15 Min. : 1.571
```

```
## 1st Qu.: 9.760 1st Qu.:63.80 1st Qu.: 5.516
```

```
## Median :13.619 Median :67.35 Median : 7.583
```

```
## Mean :14.897 Mean :67.36 Mean : 8.421
```

```
## 3rd Qu.:18.752 3rd Qu.:70.85 3rd Qu.:10.488
```

```
## Max. :51.815 Max. :86.76 Max. :38.662
```

```
## Lama_Di_Perusahaan Tingkat_Tanggung_Jawab Frekuensi_Lembur
## Min. : 1.388 Min. : 4.587 Min. : 3.302
## 1st Qu.: 5.354 1st Qu.: 7.090 1st Qu.: 6.590
## Median : 7.385 Median : 8.188 Median : 8.043
## Mean : 8.154 Mean : 8.477 Mean : 8.641
## 3rd Qu.:10.276 3rd Qu.: 9.510 3rd Qu.:10.109
## Max. :34.514 Max. :22.064 Max. :30.503
## Jumlah_Klien_Ditangani Skor_Kepemimpinan Tingkat_Stress_Kerja
## Min. : 7.192 Min. : 30.00 Min. : 5.112
## 1st Qu.:14.228 1st Qu.: 63.09 1st Qu.: 7.761
## Median :16.287 Median : 70.33 Median : 8.743
## Mean :16.462 Mean : 70.44 Mean : 8.984
## 3rd Qu.:18.476 3rd Qu.: 77.61 3rd Qu.: 9.956
## Max. :29.524 Max. :114.35 Max. :18.384
## Produktivitas_Harian Kemampuan_Komunikasi Inovasi_Dihasilkan
## Min. :11.76 Min. :27.76 Min. : 1.139
## 1st Qu.:15.37 1st Qu.:59.83 1st Qu.: 2.493
## Median :17.29 Median :65.91 Median : 3.379
## Mean :17.97 Mean :65.95 Mean : 3.958
## 3rd Qu.:19.84 3rd Qu.:72.17 3rd Qu.: 4.809
## Max. :37.07 Max. :99.04 Max. :21.030
## Ketepatan_Deadline Kolaborasi_Tim Adaptabilitas_Teknologi
## Min. : 49.39 Min. : 5.185 Min. :32.26
## 1st Qu.: 70.98 1st Qu.:40.236 1st Qu.:37.73
## Median : 76.41 Median :48.083 Median :41.28
## Mean : 76.34 Mean :48.107 Mean :42.95
## 3rd Qu.: 81.61 3rd Qu.:55.948 3rd Qu.:46.51
## Max. :110.68 Max. :98.660 Max. :84.90
## Kontribusi_Pendapatan Gaji_Bulanan
## Min. : 62.67 Min. : 87.24
## 1st Qu.: 71.03 1st Qu.:110.87
## Median : 78.83 Median :119.93
## Mean : 84.87 Mean :122.57
## 3rd Qu.: 92.84 3rd Qu.:131.35
## Max. :226.64 Max. :215.22
```

1. Konstruksi dan Diagnosis Model Awal

a. Bangun sebuah model linier dasar (Model A) yang menggunakan semua variabel fitur untuk memprediksi Gaji_Bulanan. Sajikan ringkasan statistik dari model ini.

```
ModelA <- lm(Gaji_Bulanan ~ ., data = Gaji_bulanan)
summary(ModelA)
```

```
##
## Call:
## lm(formula = Gaji_Bulanan ~ ., data = Gaji_bulanan)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.1060 -0.9133 -0.0522  0.8450  5.5626
##
```

```
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)      7.892921   0.396033  19.930 < 2e-16 ***
## Tingkat_Pendidikan  2.502013   0.007017 356.552 < 2e-16 ***
## Pengalaman_Kerja    1.786782   0.016833 106.147 < 2e-16 ***
## Pelatihan_Sertifikasi 0.785285   0.011484  68.382 < 2e-16 ***
## Jam_Kerja_Mingguan  0.299103   0.002475 120.871 < 2e-16 ***
## Jumlah_Proyek_Selesai 0.107017   0.004834  22.136 < 2e-16 ***
## Skor_Evaluasi_Kinerja 0.158440   0.004630  34.217 < 2e-16 ***
## Jumlah_Bawahan     0.496892   0.021461  23.153 < 2e-16 ***
## Lama_Di_Perusahaan  0.409280   0.012600  32.482 < 2e-16 ***
## Tingkat_Tanggung_Jawab 1.203756   0.020730  58.068 < 2e-16 ***
## Frekuensi_Lembur    0.199310   0.010665  18.689 < 2e-16 ***
## Jumlah_Klien_Ditangani 0.044187   0.006895   6.408 1.61e-10 ***
## Skor_Kepemimpinan   0.097736   0.002033  48.075 < 2e-16 ***
## Tingkat_Stress_Kerja -0.289919   0.020172 -14.372 < 2e-16 ***
## Produktivitas_Harian 0.245027   0.005506  44.502 < 2e-16 ***
## Kemampuan_Komunikasi 0.080213   0.002418  33.179 < 2e-16 ***
## Inovasi_Dihasilkan   0.408731   0.009436  43.315 < 2e-16 ***
## Ketepatan_Deadline   0.059908   0.002452  24.436 < 2e-16 ***
## Kolaborasi_Tim       0.039282   0.001666  23.585 < 2e-16 ***
## Adaptabilitas_Teknologi 0.067268   0.002783  24.168 < 2e-16 ***
## Kontribusi_Pendapatan 0.019480   0.001011  19.262 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.378 on 4979 degrees of freedom
## Multiple R-squared:  0.9928, Adjusted R-squared:  0.9928
## F-statistic: 3.454e+04 on 20 and 4979 DF,  p-value: < 2.2e-16
```

Multiple R-squared: 0.9928 artinya sekitar 99,28% variasi Gaji_Bulanan dapat dijelaskan oleh 20 variabel independen. Itu terlalu tinggi dan terindikasi mungkin ada multikolineritas antar variabel independen atau overfitting.

F-statistic: 3.454e+04, p-value: < 2.2e-16 artinya secara keseluruhan, model ini signifikan. Artinya, ada minimal satu variabel independen yang berpengaruh terhadap Gaji_Bulanan.

b. Lakukan pemeriksaan diagnostik yang komprehensif terhadap Model A. Investigasi setidaknya dua area kritis berikut:

1. Stabilitas dan Independensi Fitur: Selidiki potensi adanya ketergantungan atau redundansi informasi yang kuat di antara variabel-variabel fitur. Tunjukkan bukti kuantitatifnya dan jelaskan secara rinci bagaimana masalah ini dapat merusak keandalan dan interpretasi koefisien model.

```
vif_values <- vif(ModelA)

print("--- Hasil Uji VIF untuk Multikolinearitas ---")

## [1] "--- Hasil Uji VIF untuk Multikolinearitas ---"

print(vif_values)
```

##	Tingkat_Pendidikan	Pengalaman_Kerja	Pelatihan_Sertifikasi
##	1.137412	13.185753	1.032241
##	Jam_Kerja_Mingguan	Jumlah_Proyek_Selesai	Skor_Evaluasi_Kinerja
##	1.027735	3.104538	1.500523
##	Jumlah_Bawahan	Lama_Di_Perusahaan	Tingkat_Tanggung_Jawab
##	20.040400	6.421936	4.206146
##	Frekuensi_Lembur	Jumlah_Klien_Ditangani	Skor_Kepemimpinan
##	2.467317	1.235602	1.262586
##	Tingkat_Stress_Kerja	Produktivitas_Harian	Kemampuan_Komunikasi
##	3.029416	1.006657	1.303799
##	Inovasi_Dihasilkan	Ketepatan_Deadline	Kolaborasi_Tim
##	1.041028	1.007401	1.012677
##	Adaptabilitas_Teknologi	Kontribusi_Pendapatan	
##	1.013655	1.010419	

```

if (any(vif_values > 10)) {
  print("POSITIF MULTIKOLINEARITAS!")
  print("KESIMPULAN: Ada multikolinearitas")
  high_vif_vars <- names(vif_values[vif_values > 10])
  print(paste("Variabel dengan VIF > 10:", paste(high_vif_vars, collapse = ", ")))
} else {
  print("Tidak ada multikolinearitas yang serius (semua VIF < 10)")
}

```

```

## [1] "POSITIF MULTIKOLINEARITAS!"
## [1] "KESIMPULAN: Ada multikolinearitas"
## [1] "Variabel dengan VIF > 10: Pengalaman_Kerja, Jumlah_Bawahan"

```

```

cat("\n--- Matriks Korelasi Antar Prediktor ---\n")

```

```

##
## --- Matriks Korelasi Antar Prediktor ---

```


```

cor_matrix <- cor(Gaji_bulanan[, -which(names(Gaji_bulanan) == "Gaji_Bulanan")])

corrplot(cor_matrix,
  method = "color",
  type = "upper",
  order = "hclust",
  tl.col = "black",
  tl.cex = 0.8,
  addCoef.col = "black",
  col = colorRampPalette(brewer.pal(8, "RdBu"))(200),
  number.cex = 0.6,
  mar = c(0,0,1,0),
  title = "Heatmap Korelasi Antar Variabel Prediktor")

```

Heatmap Korelasi Antar Variabel Prediktor



Berdasarkan hasil uji VIF, ditemukan dua variabel dengan nilai VIF di atas 10, yaitu Pengalaman_Kerja (13.18) dan Jumlah_Bawahan (20.04). Hal ini menunjukkan adanya multikolinearitas kuat di antara prediktor modelA. Kondisi ini dapat menyebabkan koefisien regresi menjadi tidak stabil dan interpretasi pengaruh variabel menjadi tidak valid.

2. Perilaku Sisaan (Error): Analisis sisaan dari Model A untuk memverifikasi apakah perilakunya sesuai dengan asumsi yang mendasari sebuah model linier yang valid. Sajikan bukti visual dan jelaskan dampaknya terhadap validitas uji signifikansi (uji-t dan uji-F) dari model Anda.

Uji Normalitas (Shapiro-Wilk)

Tujuan: Menguji apakah sisaan model berdistribusi normal.

Hipotesis:

H₀: Sisaan berdistribusi normal.


H₁: Sisaan tidak berdistribusi normal.

Kriteria Keputusan: Tolak H₀ jika p-value < 0.05. Asumsi normalitas terpenuhi jika kita gagal menolak H₀ (p-value > 0.05).

```
print(shapiro.test(residuals(ModelA)))
```

```
##
## Shapiro-Wilk normality test
##
## data: residuals(ModelA)
## W = 0.99472, p-value = 1.449e-12
```

```
ggplot(data = data.frame(resid = residuals(ModelA)), aes(sample = resid)) +
  stat_qq(color = "steelblue") +
  stat_qq_line(color = "red", linewidth = 1) +
  labs(title = "Plot QQ Normalitas Residual (Model A)",
       x = "Kuantil Teoretis",
       y = "Kuantil Residual") +
  theme_minimal()
```



Nilai $W = 0.99472$ dengan $p\text{-value} = 1.449\text{e-}12$. Karena $p\text{-value} < 0.05$, maka H_0 ditolak. Artinya, residual tidak berdistribusi normal. Pada plot QQ, titik-titik menyimpang dari garis diagonal, terutama di bagian ekor, yang menunjukkan adanya penyimpangan normalitas.

Uji Homoskedastisitas (Breusch-Pagan)

Tujuan: Menguji apakah varians dari sisaan konstan (homoskedastisitas) atau tidak (heteroskedastisitas).

Hipotesis:

H_0 : Varians sisaan konstan (homoskedastisitas).

H_1 : Varians sisaan tidak konstan (terdapat heteroskedastisitas).


Kriteria Keputusan: Tolak H_0 jika $p\text{-value} < 0.05$. Asumsi homoskedastisitas terpenuhi jika kita gagal menolak H_0 ($p\text{-value} > 0.05$).

```
print(bptest(ModelA))
```

```
##
## studentized Breusch-Pagan test
```

```
##
## data: ModelA
## BP = 40.311, df = 20, p-value = 0.004562
```

```
ggplot(data = data.frame(
  fitted = fitted(ModelA),
  resid = resid(ModelA)
), aes(x = fitted, y = resid)) +
  geom_point(alpha = 0.5, color = "steelblue") +
  geom_hline(yintercept = 0, color = "red", linewidth = 1) +
  labs(title = "Plot Sisaan vs Nilai Prediksi (Model A)",
       x = "Nilai Prediksi (Fitted Values)",
       y = "Sisaan (Residuals)") +
  theme_minimal()
```



Nilai BP = 40.311 dengan p-value = 0.004562. Karena p-value < 0.05, maka H_0 ditolak. Hal ini menunjukkan adanya heteroskedastisitas, yaitu varians residual tidak konstan. Plot residual terhadap nilai prediksi menunjukkan pola melebar seperti corong, memperkuat indikasi heteroskedastisitas.

Uji Autokorelasi (Durbin-Watson)

Tujuan: Menguji apakah ada korelasi antar sisaan pada observasi yang berdekatan. Autokorelasi umumnya menjadi masalah pada data deret waktu (time series).

Hipotesis:

H_0 : Tidak ada autokorelasi (koefisien autokorelasi = 0).


H_1 : Terdapat autokorelasi.

Kriteria Keputusan: Tolak H_0 jika $p\text{-value} < 0.05$. Asumsi independensi sisaan terpenuhi jika kita gagal menolak H_0 ($p\text{-value} > 0.05$).

```
print(dwtest(ModelA))
```

```
##  
## Durbin-Watson test  
##  
## data: ModelA  
## DW = 0.27417, p-value < 2.2e-16  
## alternative hypothesis: true autocorrelation is greater than 0
```

```
acf_data <- acf(residuals(ModelA), plot = FALSE)  
acf_df <- data.frame(lag = acf_data$lag[-1],  
                     acf = acf_data$acf[-1])  
  
ggplot(acf_df, aes(x = lag, y = acf)) +  
  geom_bar(stat = "identity", fill = "steelblue") +  
  geom_hline(yintercept = 0, color = "black") +  
  geom_hline(yintercept = c(0.2, -0.2), color = "red", linetype = "dashed") +  
  labs(title = "Plot ACF Residual (Model A)",  
       x = "Lag",  
       y = "Autokorelasi") +  
  theme_minimal()
```



Nilai DW = 0.27417 dengan $p\text{-value} < 2.2e-16$. Karena $p\text{-value} < 0.05$ dan DW jauh di bawah 2, maka

terdapat autokorelasi positif yang signifikan antar residual. Plot ACF menunjukkan banyak batang autokorelasi melewati batas kepercayaan, menandakan adanya pola keterkaitan antar sisaan.

Kondisi ini menyebabkan hasil uji signifikansi (uji-t dan uji-F) menjadi tidak valid, serta interpretasi pengaruh masing-masing variabel dapat menyesatkan. Oleh karena itu, diperlukan perbaikan model.

2. Pengembangan Model Perbaikan

a. Berdasarkan setiap masalah utama yang Anda identifikasi pada langkah (1.b) usulkan dan terapkan metode pemodelan alternatif yang secara teoritis dirancang untuk mengatasi masalah tersebut. Anda diharapkan membangun setidaknya dua model perbaikan (Model B dan Model C), di mana masing-masing model menargetkan satu masalah spesifik yang telah Anda diagnosis.

Gunakan metode GLS untuk menangani masalah autokorelasi sekaligus heteroskedastisitas pada data Gaji_bulanan A.

```
Gaji_bulanan$time <- 1:nrow(Gaji_bulanan)

ModelB <- gls(Gaji_Bulanan ~ .,
              data = Gaji_bulanan,
              weights = varFixed(~Tingkat_Pendidikan),
              correlation = corAR1(form = ~time))

summary(ModelB)

## Generalized least squares fit by REML
##   Model: Gaji_Bulanan ~ .
##   Data: Gaji_bulanan
##       AIC       BIC    logLik
##  10762.8 10919.11 -5357.401
##
## Correlation Structure: AR(1)
## Formula: ~time
## Parameter estimate(s):
##      Phi
## 0.8656898
## Variance function:
## Structure: fixed weights
## Formula: ~Tingkat_Pendidikan
##
## Coefficients:
##              Value Std.Error t-value p-value
## (Intercept)    8.056362 0.17644860  45.6584  0.0000
## Tingkat_Pendidikan 2.500591 0.00442124 565.5853  0.0000
## Pengalaman_Kerja  1.809106 0.00622373 290.6788  0.0000
## Pelatihan_Sertifikasi 0.800508 0.00428224 186.9367  0.0000
## Jam_Kerja_Mingguan 0.300044 0.00092140 325.6380  0.0000
## Jumlah_Proyek_Selesai 0.100065 0.00181857  55.0240  0.0000
## Skor_Evaluasi_Kinerja 0.153087 0.00174446  87.7562  0.0000
## Jumlah_Bawahan    0.491753 0.00799094  61.5388  0.0000
## Lama_Di_Perusahaan 0.398631 0.00472503  84.3659  0.0000
## Tingkat_Tanggung_Jawab 1.210218 0.00777100 155.7353  0.0000
```

```

## Frekuensi_Lembur      0.198285 0.00396498 50.0090 0.0000
## Jumlah_Klien_Ditangani 0.045001 0.00259592 17.3353 0.0000
## Skor_Kepemimpinan     0.100469 0.00076931 130.5964 0.0000
## Tingkat_Stress_Kerja  -0.301157 0.00754195 -39.9309 0.0000
## Produktivitas_Harian   0.247872 0.00207739 119.3190 0.0000
## Kemampuan_Komunikasi   0.078147 0.00090082 86.7503 0.0000
## Inovasi_Dihasilkan     0.401969 0.00355630 113.0300 0.0000
## Ketepatan_Deadline     0.059271 0.00093406 63.4550 0.0000
## Kolaborasi_Tim         0.040622 0.00062578 64.9136 0.0000
## Adaptabilitas_Teknologi 0.070145 0.00105710 66.3561 0.0000
## Kontribusi_Pendapatan  0.020056 0.00038212 52.4861 0.0000
## time                   -0.000015 0.00003398 -0.4321 0.6657
##
## Correlation:
## (Intr) Tngk_P Pngl_K Plth_S Jm_K_M Jm_P_S Sk_E_K Jmlh_B
## Tingkat_Pendidikan    0.153
## Pengalaman_Kerja       0.101 0.002
## Pelatihan_Sertifikasi  -0.018 0.026 -0.026
## Jam_Kerja_Mingguan     -0.211 0.005 -0.007 -0.008
## Jumlah_Proyek_Selesai  -0.056 -0.018 -0.407 0.018 0.002
## Skor_Evaluasi_Kinerja  -0.377 -0.121 -0.008 -0.082 -0.027 -0.009
## Jumlah_Bawahan         -0.003 0.006 -0.675 0.030 0.007 0.018 0.010
## Lama_Di_Perusahaan     -0.022 0.003 0.102 -0.036 -0.008 -0.026 0.029 -0.591
## Tingkat_Tanggung_Jawab -0.054 0.003 -0.007 0.000 0.015 -0.006 -0.038 -0.334
## Frekuensi_Lembur       0.074 -0.001 0.011 -0.016 -0.102 0.008 0.003 -0.029
## Jumlah_Klien_Ditangani -0.184 0.002 -0.136 -0.001 0.028 -0.011 -0.014 0.009
## Skor_Kepemimpinan     -0.042 -0.036 0.018 -0.017 0.003 0.007 -0.277 0.083
## Tingkat_Stress_Kerja  -0.162 -0.001 -0.018 0.008 0.004 -0.002 0.020 0.021
## Produktivitas_Harian   -0.190 -0.011 0.028 -0.005 0.020 -0.053 -0.031 -0.004
## Kemampuan_Komunikasi   -0.026 -0.053 -0.002 0.013 -0.004 -0.003 -0.397 -0.019
## Inovasi_Dihasilkan     -0.044 -0.069 0.005 -0.128 0.006 -0.015 -0.013 0.012
## Ketepatan_Deadline     -0.365 0.004 -0.005 0.008 0.014 0.025 -0.023 -0.009
## Kolaborasi_Tim         -0.172 -0.029 -0.034 0.003 0.011 -0.007 0.047 0.027
## Adaptabilitas_Teknologi -0.231 -0.044 0.028 -0.063 0.011 0.010 0.006 -0.025
## Kontribusi_Pendapatan  -0.129 -0.007 -0.037 0.000 0.009 0.009 -0.029 0.053
## time                   -0.468 0.000 -0.004 -0.011 -0.002 0.026 -0.017 -0.008
## Lm_D_P Tn_T_J Frkn_L Jm_K_D Skr_Kp Tn_S_K Prdk_H Kmmmp_K
## Tingkat_Pendidikan
## Pengalaman_Kerja
## Pelatihan_Sertifikasi
## Jam_Kerja_Mingguan
## Jumlah_Proyek_Selesai
## Skor_Evaluasi_Kinerja
## Jumlah_Bawahan
## Lama_Di_Perusahaan
## Tingkat_Tanggung_Jawab -0.013
## Frekuensi_Lembur       0.030 0.168
## Jumlah_Klien_Ditangani 0.000 -0.010 -0.017
## Skor_Kepemimpinan     0.001 -0.261 0.006 0.016
## Tingkat_Stress_Kerja  -0.009 -0.300 -0.750 0.021 -0.005
## Produktivitas_Harian   -0.001 -0.016 -0.009 0.024 0.003 0.009
## Kemampuan_Komunikasi   0.017 0.020 -0.019 -0.054 -0.028 0.013 0.024
## Inovasi_Dihasilkan     -0.014 -0.026 -0.002 0.030 -0.010 0.011 0.001 0.001
## Ketepatan_Deadline     0.000 0.005 0.002 -0.014 0.009 -0.007 -0.022 -0.024


```

```
## Kolaborasi_Tim          -0.020  0.008  0.017 -0.007 -0.030  0.003 -0.005 -0.075
## Adaptabilitas_Teknologi 0.013 -0.022 -0.022  0.004  0.013  0.019 -0.014 -0.022
## Kontribusi_Pendapatan   -0.041 -0.013 -0.014 -0.054 -0.005  0.008 -0.032  0.001
## time                    0.000  0.006 -0.009 -0.007 -0.006  0.006  0.019  0.015
##                          Invs_D Ktpt_D Klbr_T Adpt_T Kntr_P
## Tingkat_Pendidikan
## Pengalaman_Kerja
## Pelatihan_Sertifikasi
## Jam_Kerja_Mingguan
## Jumlah_Proyek_Selesai
## Skor_Evaluasi_Kinerja
## Jumlah_Bawahan
## Lama_Di_Perusahaan
## Tingkat_Tanggung_Jawab
## Frekuensi_Lembur
## Jumlah_Klien_Ditangani
## Skor_Kepemimpinan
## Tingkat_Stress_Kerja
## Produktivitas_Harian
## Kemampuan_Komunikasi
## Inovasi_Dihasilkan
## Ketepatan_Deadline      -0.048
## Kolaborasi_Tim          0.023 -0.002
## Adaptabilitas_Teknologi 0.023  0.003 -0.008
## Kontribusi_Pendapatan   0.035 -0.030  0.020  0.004
## time                    0.014 -0.010  0.009 -0.017 -0.018
##
## Standardized residuals:
##           Min           Q1           Med           Q3           Max
## -2.98293749 -0.67404205 -0.04079867  0.60730637  4.26579269
##
## Residual standard error: 0.4233459
## Degrees of freedom: 5000 total; 4978 residual
```

```
sisaan_gls <- residuals(ModelB, type = "normalized")
fitted_gls <- fitted(ModelB)


# Validasi Heteroskedastisitas dengan Model B
plot(fitted_gls, sisaan_gls,
     main = "Sisaan vs Fitted (GLS)",
     xlab = "Fitted Values", ylab = "Normalized Residuals")
abline(h = 0, col = "red", lty = 2)
```

Sisaan vs Fitted (GLS)




```
# Validasi Autokorelasi dengan Model B
par(mfrow = c(1, 2))
acf(sisaan_gls, main = "ACF dari Sisaan GLS")
pacf(sisaan_gls, main = "PACF dari Sisaan GLS")
```

ACF dari Sisaan GLS



PACF dari Sisaan GLS



```
par(mfrow = c(1, 1))
```

Gunakan metode ridge regresi untuk menangani masalah multikolineritas pada data Gaji_bulanan.

```
x_matrix_raw <- model.matrix(Gaji_Bulanan ~ ., data = Gaji_bulanan)[, -1]
y_vector <- Gaji_bulanan$Gaji_Bulanan

x_matrix_scaled <- scale(x_matrix_raw)

set.seed(123)
cv_fit <- cv.glmnet(x_matrix_scaled, y_vector, alpha = 0) # alpha = 0 untuk Ridge
best_lambda <- cv_fit$lambda.min
print(paste("Lambda terbaik yang ditemukan:", best_lambda))
```

```
## [1] "Lambda terbaik yang ditemukan: 1.3165048753051"
```

```
ModelC <- glmnet(x_matrix_scaled, y_vector, alpha = 0, lambda = best_lambda)
```

Gunakan metode WLS untuk menangani masalah heteroskedastisitas pada data Gaji_bulanan.

```
residuals_A <- residuals(ModelA)
cor_abs <- sapply(Gaji_bulanan[, -which(names(Gaji_bulanan) == "Gaji_Bulanan")],
                  function(x) cor(abs(residuals_A), x))
sort(cor_abs, decreasing = TRUE)
```

##	Tingkat_Pendidikan	Jumlah_Proyek_Selesai	Pengalaman_Kerja
##	0.0706677066	0.0271775159	0.0268922990
##	Kemampuan_Komunikasi	Ketepatan_Deadline	Jumlah_Bawahan
##	0.0266447028	0.0249034167	0.0213796474
##	Skor_Evaluasi_Kinerja	Lama_Di_Perusahaan	Tingkat_Stress_Kerja
##	0.0198922909	0.0182363037	0.0153686265
##	Frekuensi_Lembur	Jam_Kerja_Mingguan	Tingkat_Tanggung_Jawab
##	0.0135728813	0.0129468268	0.0118202834
##	Jumlah_Klien_Ditangani	Produktivitas_Harian	Adaptabilitas_Teknologi
##	0.0096818334	0.0073465222	0.0045742231
##	Kontribusi_Pendapatan	Kolaborasi_Tim	Inovasi_Dihasilkan
##	0.0036926398	0.0002384989	-0.0040797052
##	time	Skor_Kepemimpinan	Pelatihan_Sertifikasi
##	-0.0083744207	-0.0102168645	-0.0208278309

```
bobot_wls <- 1 / Gaji_bulanan$Tingkat_Pendidikan^2
```

```
ModelD <- lm(Gaji_Bulanan ~ .,
              data = Gaji_bulanan, weights = bobot_wls)
```

```
summary(ModelD)
```

```
##
## Call:
## lm(formula = Gaji_Bulanan ~ ., data = Gaji_bulanan, weights = bobot_wls)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -0.40148 -0.08668 -0.00486  0.07887  0.63929
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      8.046e+00  3.953e-01  20.354 < 2e-16 ***
## Tingkat_Pendidikan  2.499e+00  9.538e-03 262.032 < 2e-16 ***
## Pengalaman_Kerja    1.795e+00  1.652e-02 108.633 < 2e-16 ***
## Pelatihan_Sertifikasi 7.835e-01  1.131e-02  69.287 < 2e-16 ***
## Jam_Kerja_Mingguan   2.990e-01  2.426e-03 123.262 < 2e-16 ***
## Jumlah_Proyek_Selesai 1.058e-01  4.793e-03  22.065 < 2e-16 ***
## Skor_Evaluasi_Kinerja 1.556e-01  4.551e-03  34.189 < 2e-16 ***
## Jumlah_Bawahan      4.898e-01  2.100e-02  23.320 < 2e-16 ***
## Lama_Di_Perusahaan   4.139e-01  1.240e-02  33.372 < 2e-16 ***
## Tingkat_Tanggung_Jawab 1.204e+00  2.031e-02  59.268 < 2e-16 ***
## Frekuensi_Lembur     2.014e-01  1.045e-02  19.277 < 2e-16 ***
## Jumlah_Klien_Ditangani 3.760e-02  6.741e-03   5.579 2.55e-08 ***
## Skor_Kepemimpinan    9.877e-02  1.994e-03  49.532 < 2e-16 ***
## Tingkat_Stress_Kerja -2.991e-01  1.978e-02 -15.125 < 2e-16 ***
## Produktivitas_Harian  2.485e-01  5.403e-03  45.987 < 2e-16 ***
## Kemampuan_Komunikasi  7.933e-02  2.361e-03  33.604 < 2e-16 ***
## Inovasi_Dihasilkan    4.086e-01  9.222e-03  44.306 < 2e-16 ***
## Ketepatan_Deadline    6.202e-02  2.410e-03  25.734 < 2e-16 ***
## Kolaborasi_Tim       3.894e-02  1.635e-03  23.815 < 2e-16 ***
## Adaptabilitas_Teknologi 6.828e-02  2.727e-03  25.043 < 2e-16 ***
## Kontribusi_Pendapatan  1.987e-02  9.998e-04  19.877 < 2e-16 ***
## time                -2.575e-05  1.327e-05  -1.941  0.0523 .
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.133 on 4978 degrees of freedom
## Multiple R-squared:  0.9922, Adjusted R-squared:  0.9922
## F-statistic: 3.01e+04 on 21 and 4978 DF,  p-value: < 2.2e-16
```

```
bptest(ModelD)
```

```
##
## studentized Breusch-Pagan test
##
## data: ModelD
## BP = 14, df = 21, p-value = 0.8696
```

b. Untuk setiap model perbaikan yang Anda bangun, berikan justifikasi yang jelas mengapa pendekatan tersebut adalah solusi yang tepat untuk masalah yang diidentifikasi.

Model B dibangkitkan untuk mengatasi dua permasalahan sekaligus yang masih muncul pada Model A sebelumnya, yaitu heteroskedastisitas dan autokorelasi. Berdasarkan hasil uji Durbin-Watson dengan nilai DW sebesar 0,27 dan p-value < 0,05, diketahui bahwa residual model mengalami autokorelasi positif. Untuk menangani masalah tersebut, digunakan metode Generalized Least Squares (GLS) dengan struktur korelasi autoregressive orde satu (AR(1)) yang mampu menangani korelasi antar residual dari satu observasi ke observasi berikutnya dalam data berurutan. Dari hasil Model B output plot ACF menunjukkan Hampir semua nilai ACF berada di dalam batas signifikansi (garis biru putus-putus). Tidak ada pola berulang atau lonjakan signifikan di lag tertentu artinya dengan metode GLS, autokorelasi residual sudah tertangani.

Model D dibangkitkan sebagai untuk perbaikan terhadap Model A yang sebelumnya menunjukkan adanya pelanggaran asumsi klasik berupa heteroskedastisitas, berdasarkan hasil uji Breusch-Pagan yang memiliki nilai p-value < 0,05. Kondisi ini mengindikasikan bahwa varians residual tidak konstan, sehingga Model A menjadi tidak efisien dan varians kesalahan antar pengamatan berbeda-beda. Untuk mengatasi hal tersebut, digunakan metode Weighted Least Squares (WLS) yang memberikan bobot berbeda pada setiap observasi. Bobot ditentukan berdasarkan variabel prediktor yang paling berpengaruh terhadap varians residual, yaitu variabel dengan korelasi tertinggi terhadap error. Hasil uji Breusch-Pagan dengan menggunakan metode WLS di Model D menunjukkan p-value sebesar 0.8 > 0.05 artinya menandakan metode WLS sudah menangani heteroskedastisitas.

3. Evaluasi Komparatif dan Pemilihan Model Juara

a. Buat sebuah tabel perbandingan untuk mengevaluasi performa semua model yang telah Anda bangun (Model A, Model B, Model C, dst.). Gunakan metrik yang relevan, mencakup setidaknya satu metrik untuk akurasi prediksi (contoh: RMSE atau MAE, disarankan menggunakan data validasi/testing) dan satu metrik untuk kecocokan & kompleksitas model (contoh: Adjusted R-squared, AIC, atau BIC).

```
rmse <- function(actual, pred) sqrt(mean((actual - pred)^2))

train_index <- createDataPartition(Gaji_bulanan$Gaji_Bulanan, p = 0.7, list = FALSE)
Gaji_train <- Gaji_bulanan[train_index, ]
Gaji_test <- Gaji_bulanan[-train_index, ]
```



```

# Model A
pred_A <- predict(ModelA, newdata = Gaji_test)
rmse_A <- rmse(Gaji_test$Gaji_Bulanan, pred_A)
adjR2_A <- summary(ModelA)$adj.r.squared
AIC_A <- AIC(ModelA)

# Model B
pred_B <- predict(ModelB, newdata = Gaji_test)
rmse_B <- rmse(Gaji_test$Gaji_Bulanan, pred_B)
AIC_B <- AIC(ModelB)

# Model C (Ridge Regression)
x_test_raw <- model.matrix(Gaji_Bulanan ~ ., Gaji_test)[, -1]
x_test_scaled <- scale(x_test_raw, center = attr(x_matrix_scaled, "scaled:center"),
                      scale = attr(x_matrix_scaled, "scaled:scale"))
y_test <- Gaji_test$Gaji_Bulanan

pred_C <- predict(ModelC, s = best_lambda, newx = x_test_scaled)
rmse_C <- rmse(y_test, pred_C)

# Model D (WLS)
pred_D <- predict(ModelD, newdata = Gaji_test)
rmse_D <- rmse(Gaji_test$Gaji_Bulanan, pred_D)
adjR2_D <- summary(ModelD)$adj.r.squared
AIC_D <- AIC(ModelD)

# Tabel evaluasi
evaluasi <- data.frame(
  Model = c("Model A (OLS)", "Model B (GLS)", "Model C (Ridge Regression)", "Model D (WLS)"),
  RMSE = c(rmse_A, rmse_B, rmse_C, rmse_D),
  Adjusted_R2 = c(adjR2_A, NA, NA, adjR2_D),
  AIC = c(AIC_A, AIC_B, NA, AIC_D)
)
evaluasi

```

##	Model	RMSE	Adjusted_R2	AIC
## 1	Model A (OLS)	1.364029	0.9928142	17415.49
## 2	Model B (GLS)	1.364785	NA	10762.80
## 3	Model C (Ridge Regression)	1.708008	NA	NA
## 4	Model D (WLS)	1.362995	0.9921544	17691.66

b. Pilih satu model terbaik sebagai “model juara” yang akan Anda rekomendasikan. Jelaskan alasan pilihan Anda secara komprehensif, dengan mempertimbangkan keseimbangan antara performa prediktif, stabilitas koefisien, dan pemenuhan asumsi.

Setelah mengevaluasi semua model, aku merekomendasikan Model D (WLS) sebagai model juara. Model D menunjukkan hasil prediksi paling akurat karena RMSE-nya terkecil, artinya prediksi gaji bulanan paling mendekati nilai sebenarnya. Selain itu, penggunaan bobot WLS membuat koefisien model lebih stabil dan membantu mengatasi masalah varians residual yang tidak merata, sehingga asumsi homoskedastisitas lebih terpenuhi. Meskipun Model A dan B memiliki nilai Adjusted R² dan AIC yang bagus, mereka tidak menangani heteroskedastisitas, sedangkan Model C (Ridge Regression) performa prediksinya kurang opti-

mal. Dengan mempertimbangkan akurat, stabil, dan sesuai asumsi, Model D menjadi pilihan terbaik untuk digunakan.

4. Interpretasi dan Rekomendasi Bisnis

a. Gunakan model juara pilihan Anda untuk menginterpretasikan pengaruh dari variabel yang Anda anggap paling krusial dalam menentukan Gaji_Bulanan. Pastikan interpretasi Anda jelas dan mudah dipahami.

Berdasarkan Model D, salah satu variabel yang paling krusial dalam menentukan Gaji_Bulanan adalah Tingkat_Pendidikan. Hasil model membuktikan bahwa semakin tinggi tingkat pendidikan yang ditempuh seorang karyawan maka gajinya juga akan semakin besar, hal ini masuk akal karna tingkat pendidikan mempengaruhi kemampuan (skill) dan pemahaman setiap karyawan. Variabel lain, seperti Lama Pengalaman Kerja atau Jabatan, juga berpengaruh, namun efeknya lebih kecil dibanding pendidikan.

b. Tuliskan sebuah ringkasan eksekutif (1-2 paragraf) untuk manajemen PT. Digital Cemerlang. Jelaskan dalam bahasa non-teknis mengapa analisis awal mereka bermasalah, bagaimana pendekatan Anda memperbaikinya, dan berikan dua rekomendasi strategis yang dapat ditindaklanjuti berdasarkan wawasan dari model final Anda.

Analisis awal PT. Digital Cemerlang terhadap faktor-faktor yang mempengaruhi gaji karyawan ternyata kurang akurat karena mungkin tidak memperhitungkan perbedaan karakteristik tiap karyawan dan variasi data yang ada. Dengan menggunakan metode baru saya menggunakan model WLS, model WLS mampu menyesuaikan pengaruh setiap variabel sesuai kondisi karyawan, sehingga prediksi gaji menjadi lebih tepat dan faktor-faktor penting lebih jelas terlihat, terutama tingkat pendidikan dan lama pengalaman kerja.

Berdasarkan hasil model WLS, ada dua langkah strategis yang saya rekomendasikan. Pertama, perusahaan sebaiknya meningkatkan SDM atau menyetarakan kemampuan dan pemahaman karyawan dengan pengembangan pendidikan dan pelatihan karyawan seperti workshop perusahaan, karena hal ini mampu meningkatkan gaji dan produktivitas. Kedua, struktur rekrutmen dan gaji bisa diperbaiki dengan memberi perhatian lebih pada kualifikasi pendidikan dan pengalaman, sehingga sistem gaji menjadi lebih adil, transparan, dan memotivasi karyawan untuk terus berkembang.